

長庚大學資訊工程學系

碩士論文

Graduate Institute of Computer Science and Information

Engineering

Chang Gung University

Master Thesis

運用基於生成預訓練轉換器架構的

OpenAI Whisper 多語言語音辨識引擎之

台語及華語語音辨識之實作

Taiwanese/Mandarin Speech Recognition using

OpenAI's Whisper

Multilingual Speech Recognition Engine Based on

Generative Pretrained Transformer Architecture

研究生：謝岳哲

Graduate Student: Yueh-Che Hsieh

指導教授：呂仁園 博士

Advisor: Ren-Yuan Lyu, Ph.D.

中華民國 112 年 6 月

June, 2023

長庚大學碩（博）士學位論文
指導教授推薦書

資訊工程學 系（所） 謝岳哲 君所提之論文

運用基於生成預訓練轉換器架構的 OpenAI Whisper

多語言語音辨識引擎之台語及華語語音辨識之實作 (題目)

係由本人指導撰述，同意提付審查。

指導教授 吳仁國 (簽名)

112 年 6 月 30 日

長庚大學碩（博）士學位論文
口試委員會審定書

資訊工程學系 研究所 謝岳哲 君所提之論文

（論文中文題目）運用基於生成預訓練轉換器架構的 OpenAI Whisper
多語言語音辨識引擎之台語及華語語音辨識之實作

（論文英文題目）Taiwanese/Mandarin Speech Recognition using
OpenAI's Whisper Multilingual Speech Recognition Engine Based on
Generative Pretrained Transformer Architecture

係本委員會審議，認為符合碩（博）士資格標準。

論文口試委員會

召集人 李宏毅 (簽名)

委員

蔡榮進

吳仁國

系主任、所長

陳仁暉

中華民國 112 年 6 月 30 日

摘要

本論文將對 OpenAi 的 Whisper[1]進行研究，使用基於生成預訓練轉換器架構的多語言語音辨識引擎，進行台語之語音辨識。藉由本實驗室收集的台語連續劇，和 Common Voice 的台語語料庫，我們分別對 Whisper 的 Medium 和 Large-v2 模型進行微調，將台語語音轉換成台語(閩南語)漢字與中文。我們使用字元錯誤率(Character Error Rate, CER)作為衡量標準，結果顯示兩者皆能有效辨識台語語音。藉由本次研究的成果，我們能讓使用者能使用 Whisper 進行台語語音辨識，只需要將音檔錄製即可進行辨識，增加使用者使用台語的便利性。

此外，我們也對詞彙辨識實作了即時語音辨識系統，和利用歌聲辨識實作了卡拉 OK 系統。

關鍵字：語音辨識、台語、詞彙辨識、歌聲辨識、即時系統、轉換器架構、模型微調

Abstract

This paper investigates OpenAI's Whisper [1], a multilingual speech recognition engine based on the generative pre-trained transformer architecture, for the purpose of Taiwanese speech recognition. Using a collection of Taiwanese dramas from our laboratory and the Taiwanese corpus from Common Voice, we fine-tune Whisper's Medium and Large-v2 models to convert Taiwanese speech into Minnan Chinese characters and Chinese. We evaluate the performance using the Character Error Rate (CER) as the metric, and the results show that both models are capable of accurately recognizing Taiwanese speech. With the outcomes of this study, users can utilize Whisper for Taiwanese speech recognition by simply recording audio files, enhancing the convenience of using Taiwanese.

Additionally, we have implemented a real-time speech recognition system for word recognition and a karaoke system that utilizes voice recognition for singing performance analysis.

Keywords: speech recognition, Taiwanese language, word recognition, voice recognition, real-time system, transformer architecture, model fine-tuning.

目錄

摘要.....	i
Abstract.....	ii
目錄.....	iii
圖目錄.....	vi
表目錄.....	vii
第一章 緒論.....	1
1.1 動機.....	1
1.2 目的.....	3
第二章 即時語音辨識遊戲.....	4
2.1 動機.....	4
2.2 目的.....	5
2.3 基本知識.....	5
2.3.1 語音辨識.....	5
2.3.2 語音數據收集.....	6
2.3.3 特徵提取.....	6
2.3.4 模型訓練.....	8
2.4 實驗程式.....	12
2.4.1 訓練語音辨識模型.....	12
2.4.2 即時聲控遊戲前端.....	23
2.4.3 語音辨識後端.....	35
2.5 實驗結果.....	39
2.5.1 模型訓練結果.....	39
2.5.2 介面.....	42
2.6 改進.....	45
2.6.1 個人化.....	45
2.6.2 增加詞彙與啟動詞.....	46
2.6.3 端到端模型訓練.....	47
第三章 卡拉 OK 系統.....	48
3.1 動機.....	48
3.2 目的.....	49
3.3 基本知識.....	49
3.3.1 歌聲分離.....	49
3.3.2 歌聲偵測.....	50

3.3.3	音高檢測	52
3.3.4	多線程	53
3.4	實驗程式	55
3.4.1	卡拉 OK 系統.....	55
3.4.2	歌聲辨識模型	71
3.5	實驗結果	76
3.5.1	模型訓練結果	76
3.5.2	卡拉 OK 系統.....	79
3.6	改進.....	83
3.6.1	歌詞顯示	83
3.6.2	歌唱表現力評分	84
第四章	Whisper 台語語音辨識	85
4.1	動機.....	85
4.2	目的.....	86
4.3	基本知識	86
4.3.1	whisper.....	86
4.3.2	transformer.....	87
4.3.3	輸入嵌入(Input Embedding).....	88
4.3.4	位置編碼(Positional Encoding)	89
4.3.5	自注意力機制(Self-Attention).....	90
4.3.6	前饋神經網絡(Feed-Forward Neural Network, FFN) ..	91
4.3.7	編碼器與解碼器	92
4.3.8	字元錯誤率	93
4.3.9	台語漢字	93
4.4	實驗程式	94
4.4.1	載入音訊	94
4.4.2	qkv 注意力計算	95
4.4.3	多頭注意力	97
4.4.4	注意力區塊	98
4.4.5	音訊編碼器	100
4.4.6	文本解碼器	102
4.5	實驗結果	105
4.5.1	使用模型與資料集	105
4.5.2	微調 whisper.....	107
4.5.3	辨識結果	108
4.6	未來方向	111

4.6.1 語料集	111
4.6.2 微調小型模型	111
4.6.3 驗證微調結果的辨識率	111
第五章 結論	113
參考資料	114



圖目錄

圖 2.1：即時聲控遊戲的主畫面	43
圖 2.2：語言選擇畫面	44
圖 2.3：遊戲畫面	45
圖 3.1：U-NET 網路架構圖	50
圖 3.2：鄭秀文-眉飛色舞歌聲分離與歌聲偵測結果	79
圖 3.3：程式流程圖	80
圖 3.4：選歌畫面	81
圖 3.5：麥克風錄音執行緒	82
圖 3.6：卡拉 OK 畫面	82
圖 4.1：TRANSFORMER 模型架構圖	88
圖 4.2：自注意力機制計算流程	91
圖 4.3：多頭注意力機制流程	91
圖 4.4：編碼器架構	92
圖 4.5：解碼器架構	93

表目錄

表 2.1：特徵提取函數	13
表 2.2：不同語言的音檔長度與錄音人數	39
表 2.3：語音辨識訓練參數	40
表 2.4：CNN 模型架構與參數	41
表 2.5：語音辨識結果	42
表 3.1：歌聲偵測訓練參數	77
表 3.2：LRCN 網路模型	78
表 3.3：歌聲偵測訓練結果	78
表 4.1：臺灣閩南語推薦用字 700 字表簡例	94
表 4.2：COMMON VOICE NAN-TW 資料集內容	106
表 4.3：台語連續劇資料集內容	107
表 4.4：微調的主要參數	108
表 4.5：對 COMMON VOICE ZH-TW 語料集進行 FINE-TUNE 之結果	108
表 4.6：對 COMMON VOICE NAN-TW 語料集進行 FINE-TUNE 之結果 .	108
表 4.7：對台語連續劇進行 FINE-TUNE 之結果	109
表 4.8：台語輸出微調辨識結果	109
表 4.9：華語輸出微調辨識結果	109